

# Denoising de grano fotográfico

## Tratamiento estadístico de señales

### Trabajo de fin de curso | Curso 2010

Martín Etchart | mrt.n.etchart@gmail.com  
Tutor: Pablo Musé

22.08.2011

#### Resumen

Film Grain Noise. Enfoque basado en Unscented Kalman Filter (UKF) y prior no-gaussiano para la remoción del *grano* presente en la adquisición de imágenes de forma analógica.

## 1. Introducción

### Motivación

El fenómeno del *film grain noise* o *ruido de grano* es una característica intrínseca de la película fotográfica. Con la evolución de la tecnología y la resolución de los dispositivos este ruido es ahora claramente apreciable en dispositivos de alta resolución. Su presencia afecta la tasa de compresión por contener componentes significativas de alta frecuencia y puede resultar molesto si es excesivo. El filtrado tradicional, asumiendo ruido gaussiano y aditivo, de dicho ruido para compresión eficiente no constituye una real aproximación al problema y resultaría en la pérdida de detalle en la imagen y/o en un filtrado incorrecto de dicho ruido, por ejemplo *rompiendo el grano* sin eliminarlo.

Por otro lado el *grano* es un elemento codiciado por cinéfilos ya que se dice intensifica la sensación visual de la imagen y es un elemento ausente en imágenes creadas sintéticamente o adquiridas por medio de sensores electrónicos. Tanto en estos casos como en casos en donde se remueve el ruido para tener mejores tasas de compresión es de utilidad poder generar sintéticamente dicho ruido.

### Composición de la película y proceso químico

En su composición química la película fotográfica consiste de una emulsión sensible a la luz recubierta por una capa plástica. Esta emulsión contiene granos de haluro de plata las cuales, en su versión mas simple, absorben la luz y generan un foto-electrón y un hueco. El foto-electrón es capturado por una trampa de electrones y atrae y reacciona con un ion de plata del entorno formando un átomo de plata

llamado *centro de pre-imagen latente*. La repetición de este fenómeno en el mismo centro de imagen lleva a la formación de *centros de imagen latentes* compuestos de clusters de átomos de plata [1]. El tamaño de los granos determina la velocidad o sensibilidad de la cinta (estándar ISO, ASA), cuanto mas chicos los granos, mas fino será el detalle y mas lento será el proceso.

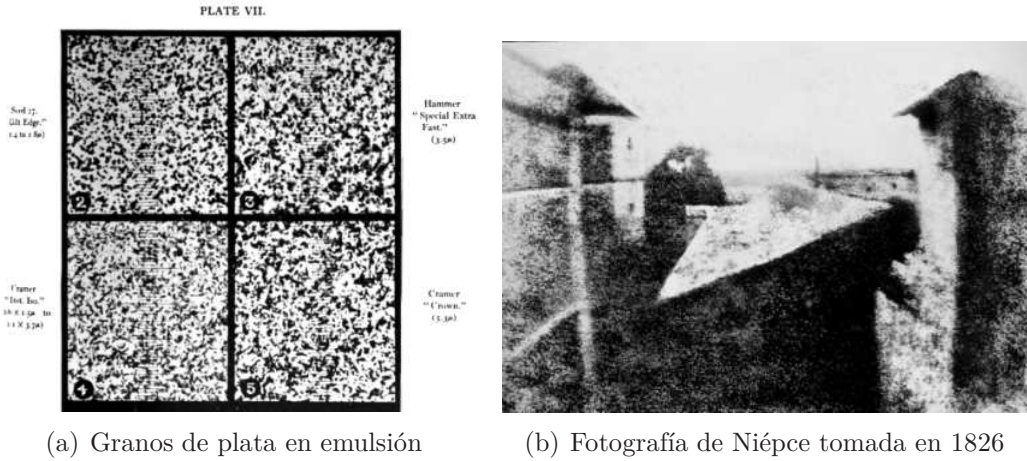


Figura 1:

## Modelado

A partir de esta breve descripción se puede ver como el proceso óptico y químico de la película fotográfica resulta complejo de modelar precisamente y de ser posible, no resultaría manejable [2]. De todas formas hay una bien conocida relación no lineal entre la densidad de plata en la película fotográfica y la intensidad de la luz incidente (exposición) dada por la curva  $D = \alpha \log E + \beta$  de donde se puede extraer información para un modelado simplificado pero suficientemente preciso. Los fabricantes de películas fotográficas pueden, en algunos casos, proporcionar la curva o los parámetros  $(\alpha, \beta)$ .

Para afrontar el problema en lo que sigue nos basaremos principalmente en [3] en donde se definen dos dominios, el *dominio de densidad*, en donde toma lugar la formación de la película y el dominio de exposición en donde la imagen esta disponible para su consumo visual. Parece razonable entonces modelar el fenómeno del *ruido de grano* como ruido Gaussiano aditivo en el dominio de la densidad ya que contamos con la curva  $D - \log E$  de donde obtenemos,  $r_d(m, n) = \alpha \log_{10}(s(m, n)) + \beta + v(m, n)$ . Aquí  $s(m, n)$  es la escena original,  $r_d(m, n)$  es la observación degradada en el *dominio de densidad* y  $v(m, n)$  es ruido gaussiano de media nula y varianza  $\sigma_v^2$ . Alternativamente podemos reescribir esta expresión como

$$r_e(m, n) = s(m, n) \left( 10^{v(m, n)/\alpha} \right) \quad (1)$$

en donde  $r_e(m, n)$  es la imagen degradada en el *dominio de exposición* y se relaciona a  $r_d(m, n)$  como  $r_d(m, n) = \alpha \log_{10}(r_e(m, n)) + \beta$ .

Se ve entonces en (1) que el ruido se torna multiplicativo y no Gaussiano. Para tratar con esta no linealidad se propone un *Unscented Kalman Filter* que preserve la información de borde incorporando un prior basado en un *Markov Random Field* (MRF) en el marco UKF y estimando sus estadísticas mediante *Monte Carlo Sampling*. En la sección 2 se muestra el prior no gaussiano y su característica de adaptación a discontinuidades mientras que en la sección 3 se explica la técnica de muestreo de Monte Carlo para estimar las estadísticas del prior. En la sección 4 se verá la estructura del *Unscented Kalman Filter* y su extensión para la incorporación de dicho prior a la vez que se detalla el algoritmo de filtrado. Por último en la sección 6 se muestran resultados para degradación sintética y real y se analizan los resultados.

## 2. MRF prior no-Gaussiano

En el marco de Kalman debemos contar con un modelo en variables de estado lo cual es equivalente a poder escribir el problema como un proceso ARMA. Un modelo lineal AR homogéneo para la evolución del estado impone una fuerte restricción en su evolución y puede impedir transiciones reales en la imagen así como un prior Gaussiano imponer suavidad. Por otro lado un *Markov Random Field* posee una propiedad Markoviana—el valor de un pixel depende solamente de los valores de sus píxeles vecinos [4]. De esta forma se puede ver un parecido intuitivo en la idea de un proceso AR y un MRF pero con la salvedad de que en este último tenemos libertad para relajar la condición de dependencia en ciertos contextos como son los bordes de una imagen. El MRF propuesto es un regularizador continuo y adaptivo que preserva las discontinuidades en la imagen.

Se modela entonces, en la imagen, la escena  $s$  como un MRF no-Gaussiano con densidad de probabilidad condicional dada por

$$P(s(m, n) | \hat{s}(m - i, n - j)) = \frac{1}{Z} \exp \left( -\gamma \log \left( 1 + \frac{\eta^2(s(m, n), \hat{s})}{\gamma} \right) \right) \quad (2)$$

en donde  $Z$  es una constante de normalización y

$$\eta^2(s(m, n), \hat{s}) = \frac{1}{\rho^2(m, n)} \sum_{(i, j) \in \Omega} \frac{(s(m, n) - \hat{s}(m - i, n - j))^2}{(i^2 + j^2)}. \quad (3)$$

Se toma el semiplano no simétrico como soporte y se acota el conjunto de vecinos a quienes que cumplen  $\Omega = \{(i, j) : (0, 1), (1, 1), (1, 0), (1, -1)\}$ . La variación permitida del pixel actual con respecto a sus vecinos esta controlada por el parámetro  $\rho^2(m, n)$ .

Podemos identificar la función potencial del MRF como el término  $\gamma \log(1 + \frac{\eta^2}{\gamma})$ . En la figura 2 se muestra el grado de falta dictado por la función potencial frente a distintos valores de  $\eta$ . Se identifican dos regiones, una convexa y una no convexa. La primera de estas regiones es una banda  $B_\gamma = (-\sqrt{\gamma}, \sqrt{\gamma})$  correspondiente a un conjunto de píxeles muy parecidos, o *cercanos*, en donde fuerza de suavizado del regularizador aumenta de forma monótona a medida que  $\eta$  aumenta. Fuera de la banda el suavizado decrece hasta valer cero cuando  $\eta \rightarrow \infty$ .

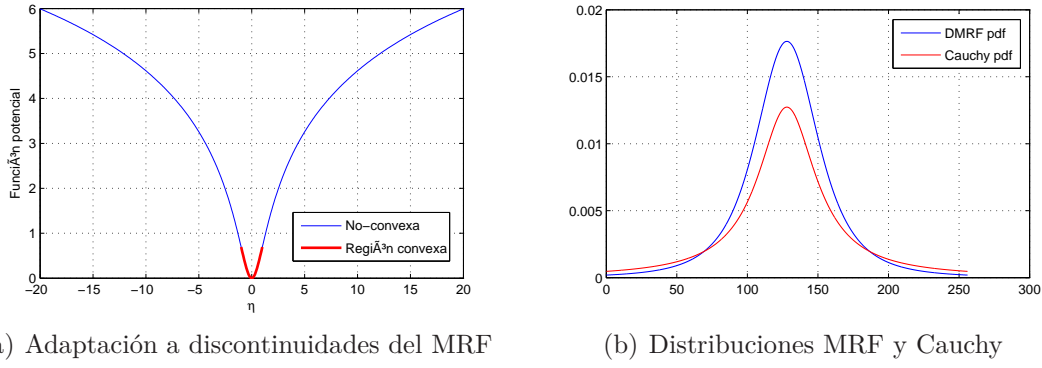


Figura 2: Propiedades del prior

### 3. Sampling

Para incorporar el prior no-Gaussiano de la sección anterior al marco UKF debemos ser capaces de obtener la media y covarianza de éste. Es por ello que se explica un método de muestreo de Monte Carlo llamado *Importance Sampling*.

Supongamos que tenemos una PDF  $p(z)$  conocida hasta una constante multiplicativa de la cual queremos obtener sus momentos. Este método determina estimadores de la PDF objetivo usando muestras de una distribución auxiliar  $q(z)$  la cual es fácil de muestrear y es una aproximación razonable de  $p(z)$ . Esta basado en la idea de la utilización de pesos para corregir el hecho que estamos muestreando de una distribución auxiliar en lugar de la distribución objetivo [5]. Matemáticamente se puede escribir como

$$\begin{aligned}
 E_p\{h(z)\} &= \int p(z)h(z)dz = \int q(z)\frac{p(z)}{q(z)}h(z)dz \\
 &= E_q\left\{\frac{p(z)}{q(z)}h(z)\right\} \approx \frac{1}{L} \sum_{i=1}^L h(z^{(l)}) \left(\frac{p(z^{(l)})}{q(z^{(l)})}\right)
 \end{aligned} \tag{4}$$

en donde  $z^{(l)}$  son muestras de la distribución auxiliar  $q$  con  $l = 1 \dots L$  y llamamos pesos de corrección a los  $w^l = \frac{p(z^{(l)})}{q(z^{(l)})}$ . Dado que los  $w^l$  no necesariamente suman  $L$  consideramos la versión auto normalizada. Sea  $\hat{\mu}$  un estimador de  $E_p\{h(z)\}$

$$\hat{\mu} := \frac{\sum_{i=1}^L w^l h(z^l)}{\sum_{i=1}^L w^l}. \tag{5}$$

Si deseamos estimar media y covarianza de  $p$  siguiendo (5) tenemos

$$\hat{\mu}_p = \frac{\sum_{i=1}^L w^l z^l}{\sum_{i=1}^L w^l}, \quad \hat{\sigma}_p^2 = \frac{\sum_{i=1}^L w^l (z^l - \hat{\mu}_p)^2}{\sum_{i=1}^L w^l} \tag{6}$$

Volviendo al problema concreto, nuestra distribución objetivo  $p$  correspondería al DAMRF presentado en la sección anterior y la distribución auxiliar  $q$  elegida corresponde a una Cauchy por su naturaleza *heavy-tailed* lo cual asegura que el soporte de  $p$  este en el de  $q$ . La PDF de Cauchy y su CDF estan dadas por

$$q(z; k_1, s_1) = \frac{1}{\pi s_1 \left(1 + \frac{(z-k_1)^2}{s_1^2}\right)} \quad Q(z; k_1, s_1) = \frac{1}{\pi} \arctan\left(\frac{z-k_1}{s_1}\right) + \frac{1}{2} \tag{7}$$

Por lo que podemos utilizar su iCDF y muestrear de una uniforme  $u \sim U_{[0,1]}$  y obtener muestras de la Cauchy como

$$z = k_1 + s_1 \tan(\pi(u - 0,5)).$$

En la figura 2 se muestran las densidades de ambas distribuciones en donde se puede apreciar que la Cauchy tiene una cola mas pesada.

## Monte Carlo Sampling

Se verá mas adelante que es necesario para muestrear mediante la Cauchy un estimador de  $s_1$ , la dispersión, en cada iteración del filtro. No fue posible encontrar una expresión analítica que permita tener en cada iteración un valor de  $s_1$  que minimice la varianza del estimador de IS. Debido a que este factor es complejo de estimar e influye notablemente en los resultados, se demostró mediante los experimentos que un Muestreo de Monte Carlo tradicional, es decir con una distribución auxiliar uniforme que cubra todo el soporte ( $0 \dots 255$ ) produjo mejores resultados que la Cauchy. Se llegó a esto con la observación de que los resultados comenzaban a ser razonables a medida que se utilizaba  $s_1$  tal que cubra todo el soporte de intensidades de los pixeles y en donde la Cauchy se tornaba casi plana. En el límite, la forma de la distribución es una uniforme. Utilizar una uniforme trae la ventaja frente a la cauchy con soporte amplio que no se muestrea por afuera del soporte de  $0 \dots 255$ .

Si se lograra una buena estimación del parámetro  $s_1$  se aceleraría la convergencia del estimador IS y por la tanto bajar el numero de muestras necesarias y el tiempo de computo.

## 4. Unscented Kalman Filter

El UFK es una contraparte no lineal del filtro de Kalman y es una aplicación de la *Unscented Transform* (UT). La UT es un enfoque de muestreo determinístico para calcular las estadísticas de una variable aleatoria que experimenta una transformación no lineal.

### Unscented Transform

Sea  $\mathbf{x}$  una variable aleatoria que se propaga por la función no lineal  $\mathbf{g} : R^{n_x} \rightarrow R^{n_y} : \mathbf{y} = \mathbf{g}(\mathbf{x})$ . Se eligen  $2n_x + 1$   $\sigma$ -points determinísticamente tal que capturan exactamente la media y covarianza real de la variable aleatoria  $\mathbf{x}$  de la siguiente forma

$$\mathbf{X}_0 = \bar{\mathbf{x}}, \quad \mathbf{X}_i = \bar{\mathbf{x}} \pm \left( \sqrt{(n_x + \lambda)\mathbf{P}} \right) \quad (8)$$

$$\begin{aligned} w_0^\mu &= \frac{\lambda}{(n_x + \lambda)}, & w_i^\mu &= w_i^c = \frac{1}{2(n_x + \lambda)} \\ w_0^c &= w_0^\mu + (1 - \alpha_{UT}^2 + \beta_{UT}) & i &= 1, \dots, 2n_x \end{aligned} \quad (9)$$

Con  $\lambda = \alpha_{UT}^2(n_x + \kappa) - n_x$  parametros de ajuste de la UT. Se puede ver que este conjunto de  $\sigma$ -points es un conjuntos de puntos centrados en  $\mathbf{x}$  simétricos y capturan exactamente los dos primeros momentos de la variable aleatoria  $\mathbf{x}$ . A cada  $\sigma$ -point se lo propaga mediante  $\mathbf{Y}_i = \mathbf{g}(\mathbf{X}_i)$  y se estiman media y covarianza de  $\mathbf{y}$  como

$$\bar{\mathbf{y}} = \sum_{i=0}^{2n_x} w_i^\mu \mathbf{Y}_i, \quad \mathbf{P}_y = \sum_{i=0}^{2n_x} w_i^c (\mathbf{Y}_i - \bar{\mathbf{y}})(\mathbf{Y}_i - \bar{\mathbf{y}})^T \quad (10)$$

Estos estimadores son precisos hasta el segundo orden de la expansión en series de Taylor para cualquier función no lineal  $\mathbf{g}(\mathbf{x})$ .

## Extensión del UKF

Se extiende la estructura básica del UKF para incorporar el prior no-Gaussiano. Esta extensión se basa en la observación de que las variantes del filtro de Kalman difieren solamente en la propagación de estados pero tienen las misma ecuaciones de actualización. El paso de predicción del estado se realiza estimando los momentos del prior dados por el modelo DAMRF. Se aumenta el estado y se determinan los  $\sigma$ -points en el marco UKF para luego propagarlos por la no linealidad y actualizar el estado.

Para una imagen de tamaño  $M \times N$ , los pixeles se recorren en forma de *raster scan* evitando los bordes y asumiendo que su valor es el de la escena estimada  $\hat{s}$ . A continuación se detallan los pasos.

### Paso 1

En cada pixel se construye la PDF condicional en (2) utilizando los pixeles vecinos en el soporte del semiplano no-simétrico, los cuales ya fueron estimados  $s(m-1, n+1)$ ,  $s(m-1, n)$ ,  $s(m-1, n-1)$  y  $s(m-1, n+1)$ . Dado que el parámetro  $\rho(m, n)^2$  caracteriza la dependencia local se fija a la covarianza del estado anterior  $\mathbf{P}_{(m, n-1)}$ .

$$P(s(m, n) | \hat{s}(m-i, n-j)) = \exp \left( -\gamma \log \left( 1 + \frac{\eta^2(s(m, n), \hat{s})}{\gamma} \right) \right)$$

### Paso 2

Se obtiene media y covarianza de la PDF anterior mediante importance sampling mediante 6. Para la distribución auxiliar se utiliza una distribución uniforme tal que abarque todo el rango de intensidades de los pixeles,  $\mathcal{U}_{[0, 255]}$ .

$$\hat{\mu}_p = \frac{\sum_{l=1}^L w^l z^l}{\sum_{l=1}^L w^l}, \quad \hat{\sigma}_p^2 = \frac{\sum_{l=1}^L w^l (z^l - \hat{\mu}_p)^2}{\sum_{l=1}^L w^l}$$

### Paso 3

Se usan los estimadores para aumentar el estado y obtener la matriz de  $\sigma$ -points. La dimensión del estado aumentado es  $n_a = 2$  dado que no es necesario aumentar el ruido de estado ya que la predicción se basa directamente en la PDF del prior.

$$\bar{\mathbf{x}}_{(m, n) | (m, n-1)} = \hat{\mu}_p$$

$$\begin{aligned}\bar{\mathbf{P}}_{(m,n)|(m,n-1)} &= \hat{\sigma}_p^2 \\ \bar{\mathbf{x}}_{(m,n)|(m,n-1)}^{\mathbf{a}} &= \begin{bmatrix} \bar{\mathbf{x}}_{(m,n)|(m,n-1)} & \mathbf{0} \end{bmatrix}^T = \begin{bmatrix} \hat{\mu}_p & \mathbf{0} \end{bmatrix}^T \\ \bar{\mathbf{P}}_{(m,n)|(m,n-1)}^{\mathbf{a}} &= \begin{bmatrix} \bar{\mathbf{P}}_{(m,n)|(m,n-1)} & \mathbf{0} \\ \mathbf{0} & \sigma_v^2 \end{bmatrix} = \begin{bmatrix} \hat{\sigma}_p^2 & \mathbf{0} \\ \mathbf{0} & \sigma_v^2 \end{bmatrix}\end{aligned}$$

La matriz de  $\sigma$ -points se calcula mediante (8) como

$$\mathbf{X}_{(m,n)|(m,n-1)}^{\mathbf{a}} = \begin{bmatrix} \bar{\mathbf{x}}_{(m,n)|(m,n-1)}^{\mathbf{a}} & \bar{\mathbf{x}}_{(m,n)|(m,n-1)}^{\mathbf{a}} \pm \left( \sqrt{(n_a + \lambda) \bar{\mathbf{P}}_{(m,n)|(m,n-1)}} \right) \end{bmatrix}$$

#### Paso 4

Para este paso se propaga la matriz  $\mathbf{X}_{(m,n)|(m,n-1)}^{\mathbf{a}}$  con los en el por la no linealidad de la película fotográfica (1) elemento a elemento obteniendo

$$\mathbf{Y}_{(m,n)|(m,n-1)} = \mathbf{h} \left( \mathbf{X}_{(m,n)|(m,n-1)}^x, \mathbf{X}_{(m,n-1)}^v \right) = \mathbf{X}_{(m,n)|(m,n-1)}^x, 10^{\left( \mathbf{x}_{(m,n-1)}^v / \alpha \right)}$$

en donde  $\mathbf{X}_{(m,n)|(m,n-1)}^x$  y  $\mathbf{X}_{(m,n-1)}^v$  son la primera y segunda fila de la matriz  $\mathbf{X}_{(m,n)|(m,n-1)}^{\mathbf{a}}$  respectivamente.

#### Paso 5

Una vez propagados los  $\sigma$ -points obtenemos mediante 10 las estadísticas necesarias para la actualización

$$\begin{aligned}\bar{\mathbf{y}} &= \sum_{i=0}^{2n_a} w_i^\mu \mathbf{Y}_{i,(m,n)|(m,n-1)}^a \\ \mathbf{P}_{yy} &= \sum_{i=0}^{2n_a} w_i^c (\mathbf{Y}_{i,(m,n)|(m,n-1)}^a - \bar{\mathbf{y}})(\mathbf{Y}_{i,(m,n)|(m,n-1)}^a - \bar{\mathbf{y}})^T \\ \mathbf{P}_{xy} &= \sum_{i=0}^{2n_a} w_i^c (\mathbf{X}_{i,(m,n)|m,n-1}^x - \bar{\mathbf{x}}_{(m,n)|(m,n-1)})(\mathbf{Y}_{i,(m,n)|(m,n-1)}^a - \bar{\mathbf{y}})^T\end{aligned}$$

#### Paso 6

En el último paso se calcula la ganancia de Kalman como  $\mathbf{K}_{(m,n)} = \mathbf{P}_{xy}^{-1} \mathbf{P}_{yy}$  y se actualiza el estado y la matriz de covarianza

$$\begin{aligned}\bar{\mathbf{x}}_{(m,n)} &= \bar{\mathbf{x}}_{(m,n)} + \mathbf{K}_{(m,n)} \left( y_{(m,n)} - \mathbf{y}_{(m,n)|(m,n-1)} \right) \\ \mathbf{P}_{(m,n)} &= \mathbf{P}_{(m,n)|(m,n-1)} - \mathbf{K}_{(m,n)} \mathbf{P}_{yy} \mathbf{K}_{(m,n)}^T\end{aligned}$$

en donde  $y_{(m,n)}$  corresponde a la imagen degradada en el dominio de la exposición. La imagen filtrada resulta ser  $\hat{s}(m, n) = \bar{\mathbf{x}}_{(m,n)}$ .



## 5. Resultados

Para probar la eficacia del filtro se probó en primera instancia con imágenes sintéticas para ver el rango de parámetros en donde el filtro funciona mejor. A partir de este análisis se utilizan los parámetros encontrados para caso de degradación real en donde se ajustan según el caso.

Se fijan los valores del UKF a  $\alpha_{UT} = 1$ ,  $\beta_{UT} = 0$  y  $\kappa = 1$  dado el filtro es robusto frente a variaciones en estos. De la curva  $D - \log E$  se obtiene un valor de  $\alpha = 5$  y  $\beta = 0$  el cual se fija para todos los experimentos. La cantidad de muestras para el Monte Carlo Sampling se fija en  $L = 100$  muestras.

Parámetros como  $\gamma$  son críticos en el desempeño del filtro. Como ya se vio del análisis del DAMRF el parámetro  $\gamma$  controla la banda convexa en donde toma fuerza el suavizado basado en la medida de distancia entre la intensidad de los pixeles vecinos. Por lo tanto es esperable que la variación de este parámetro aumente el suavizado cuando aumenta así como que relaje la condición de borde. Una elección apropiada de  $\gamma$  permitirá suavizar eliminando el ruido de grano y a su vez preservar los bordes.

El tiempo de ejecución del filtrado resultó muy eficiente para una implementación en MATLAB. Para imágenes de  $200 \times 200$  en una CORE 2 Duo fue de 10 segundos mientras que los de [3] aseguran que les toma 18 segundos en una Pentium 4.

### Degradación sintética

Para la degradación sintética se generó ruido a diferentes niveles y se midió la mejora en la relación señal a ruido. Si  $r_e$  es la imagen degradada,  $s$  la imagen original y  $\hat{s}$  la estimada en el dominio de la exposición, entonces se define (improvement in signal to noise ratio)


$$ISNR = 10 \log_{10} \left( \frac{\sum_{m,n} (r_e(m,n) - s(m,n))^2}{\sum_{m,n} (\hat{s}(m,n) - s(m,n))^2} \right) dB.$$

La imagen degradada se generó mediante la ecuación de la observaciones en el dominio de la exposición (1) a partir de la imagen de Lena.

En la figura 3 se muestran los resultados para degradación sintética 3(b) para la imagen de Lena 3(a). Se utilizó para este experimento un nivel de ruido  $\sigma_v^2 = 0,01$  y diferentes valores de  $\gamma$ . Este nivel de ruido resulta sumamente razonable para escenas naturales y en condiciones normales. Se puede observar que el ruido es leve pero notorio y esta mas presente en las zonas claras de la imagen según la ecuación de la película fotográfica. La imagen estimada en 3(c) logra minimizar la presencia del ruido pero sin eliminarlo completamente. Por otro lado 3(d) el ruido se logra minimizar notablemente y se conserva la información de borde y detalle como las plumas y el pelo. En las zonas planas de la imagen la imagen estimada resulta plana y solo le nota pérdida de detalle en zonas complejas como es la textura del sombrero.

En condiciones mas ruidosas como ser  $\sigma_v^2 = 0,05$  la imagen degradada ya no resulta natural y los resultados del no son tan agradables visualmente. En la figura 4 se muestra la imagen degradada y resultados para esta. El caso de 4(b) el método no logra remover el ruido y para 4(c) el ruido es removido pero aparecen artefactos





(e) Perfil para la fila 150 para ruido sintético  $\sigma_v^2 = 0,01$ ,  $\gamma = 1,8$  con Lena.

Figura 3: Resultados para ruido sintético  $\sigma_v^2 = 0,01$  con Lena.

del tipo de *borroneos*. Cuando el nivel de ruido es superior el filtro confía menos en las las observaciones y mas en el prior DAMRF (lo que sería la ecuación de estado). Esto sumado a el uso del  $\gamma$  mas grande produce suavizado en regiones que perceptualmente son bordes pero el prior no los identifica como tal por estar dentro de la región convexa.

Para el caso mas realista y que mejor resultados produce,  $\sigma_v^2 = 0,01$  y  $\gamma = 1,8$  se muestra en la figura 4(d) un perfil de la evolución del estado en una fila de la imagen, degradada y estimada. Se puede observar como en valores de intensidad altos el ruido es mas presente y el filtro actúa suavizando la evolución mientras que en zonas de bajo nivel de intensidad la señal filtrada sigue la señal degradada. También se puede ver la adaptación del filtro a discontinuidades o cambios abruptos




Figura 4: Resultados para ruido sintético  $\sigma_v^2 = 0,05$  con Lena.

de la señal como lo son los bordes de la imagen.

De forma de tener resultados objetivos sobre las imágenes degradadas es que se calcula el MSE y el ISNR los cuales se muestran en el cuadro 1. Se toman niveles de ruido razonables a altos y se comparan los resultados. Para el caso de  $\sigma_v^2 = 0,01$  se pueden corroborar las observaciones con los resultados numéricos. El filtro con  $\gamma = 1,8$  produce mejores resultados ya que el MSE es menor con respecto al caso  $\gamma = 1,3$  y el ISNR es mayor. Para el caso  $\sigma_v^2 = 0,05$  las medidas de desempeño marcan una muy leve mejoría para el caso  $\gamma = 1,8$  lo que se condice con las observaciones visuales previamente realizadas. El caso de alto nivel de ruido el filtro no logra un buen desempeño pero produce resultados mas naturales y mejores cuantitativamente para  $\gamma = 1,3$  aun que no logra remover el ruido completamente.

$\sigma_v^2 \setminus \gamma$	MSE		ISNR(dB)	
	<b>1.3</b>	<b>1.8</b>	<b>1.3</b>	<b>1.8</b>
<b>0.01</b>	25	21	1,55	2,41
<b>0.05</b>	92	90	3,05	3,08
<b>0.10</b>	144	162	4,12	3,67

Cuadro 1: MSE y ISNR para degradación sintética de Lena con distintos niveles de ruido y  $\gamma$ .

## Degradación real

Para todos los caso de degradación real se utilizó  $\gamma = 1,3$  dado que lleva a resultados mas naturales visualmente. Se utilizó una fotografía de Johnny Cash en blanco y negro de tamaño  $431 \times 600$  pixeles para los experimentos. En la figura ??(a) se muestra la imagen original en donde se puede percibir la presencia de ruido de grano con el mismo patrón previamente analizado para ruido sintético confirmando la dependencia del ruido con el nivel de intensidad en la señal. Se puede notar claramente en la cara como en el la superficie a la derecha. No se ve ruido por ejemplo en las zonas negras de la imagen como el pelo o la ventana entre las rejas.

En la figura 5(b) se puede ver la imagen estimada para  $\gamma = 1,3$  en donde se logra eliminar en gran medida el ruido de grano y logrando resultados naturales. En la figura 5(c) se puede ver que un valor mas alto de  $\gamma$  lleva a los mismos artefactos que para las imágenes sintéticas.

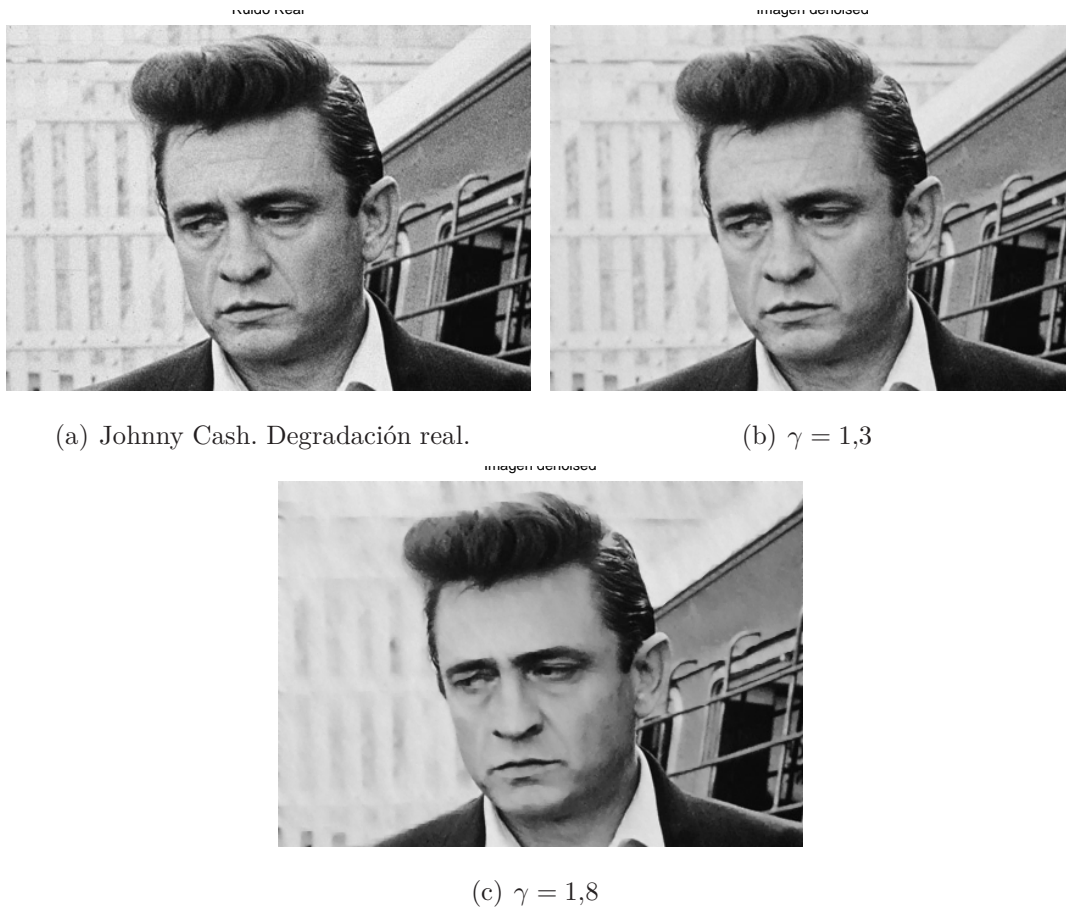


Figura 5: Resultados para degradación real con  $\sigma_v^2 = 0,1$  en cada canal de color.  $\gamma = 1,3$ .

## Color

Se realizaron pruebas para degradación real en imágenes a color. Para tratar el color, se tomó el criterio de trabajar cada canal por separado puesto que las

películas fotográficas a color contienen emulsiones apiladas por color. Para hacer un mejor tratamiento se deberían tomar en cuenta diferentes niveles de ruido según cada canal ya que la emulsiones reaccionan distinto canales como el azul, necesitan de mas densidad de grano para reaccionar. En la figura ?? se muestran los resultados para un experimento con color. Los parámetros elegidos logran remover sutilmente el ruido sin suavizar en exceso la imagen. El residuo muestra como el ruido es removido en zonas de la imagen mas claras preservando los bordes.




Figura 6: Resultados para degradación real con  $\sigma_v^2 = 0,05$  en cada canal de color.  $\gamma = 1,3$ .

## Referencias

- [1] T. Tadaaki. *Photographic Sensitivity: Theory and Mechanisms*. Oxford University Press, 1995.
- [2] J. Yan, P. Campisi, D. Hatzinakos. *Film Grain Noise Removal and Generation for Color Images*. Proceedings from the 1998 IEEE International Conference.
- [3] G. Subrahmanyam, A. Rajagoplan, R. Aravind. *Importance Sampling-Based Unscented Kalman Filter for Film-Grain Noise Removal*. IEEE Multimedia Magazine, 2008.
- [4] S. Li. *Markov Random Field Modeling in Computer Vision*. Springer Verlag, 1995.
- [5] A. Johansen. L. Evers. *Monte Carlo Methods*. University of Bristol, Department of Mathematics, 2007.